Libco 源码分析

状态 ：	文件标签:	Libco 源码分析
[ ] 草稿	版本:	V1.0
[V] 修改中	作者:	张鸿
[ ] 定稿	日期:	2018-8-26

编辑历史

文件名称：Libco 源码分析				
文件说明：				
编辑历史：				
编辑时间	版本	作者	编辑内容	标记
2018-8-26	1.0	张鸿	初稿	

目 录

1 说明

libco 是腾讯开源的一个协程库，主要应用于微信后台 RPC 框架;

https://github.com/Tencent/libco

2 什么是协程？

协程，又称微线程，纤程。英文名 Coroutine。协程是一种用户态的轻量级线程，协程的调度完全由用户控制，协程拥有自己的寄存器上下文和栈；

2.1 协程与线程的区别

1） 线程是通过内核来调度的，而协程是用户态调度的；

2） 线程进程都是同步机制，而协程则是异步；

3） CPU 密集型应用适用于单进程或者多进程，IO 密集型应用则适用于协程；

生产者与消息者示例：

```
void* Producer(void* args)
{
    co_enable_hook_sys();
    stEnv_t* env=  (stEnv_t*)args;
    int id = 0;
    while (true)
    {
        stTask_t* task = (stTask_t*)calloc(1, sizeof(stTask_t));
        task->id = id++;
        env->task_queue.push(task);
        printf("%s:%d produce task %d\n", __func__, __LINE__, task->id);
        co_cond_signal(env->cond);
        poll(NULL, 0, 3000);
    }
    return NULL;//每 3 秒都会执行一次，先打印 printf，再执行这里；
}
void* Consumer(void* args)
{
    co_enable_hook_sys();
    stEnv_t* env = (stEnv_t*)args;
    while (true)
    {
        if (env->task_queue.empty())
        {
            co_cond_timedwait(env->cond, -1);
            continue;
        }
        stTask_t* task = env->task_queue.front();
        env->task_queue.pop();
        printf("%s:%d consume task %d\n", __func__, __LINE__, task->id);
        free(task);
    }
    return NULL;
}
int main()
{
    stEnv_t* env = new stEnv_t;
    env->cond = co_cond_alloc();

    stCoRoutine_t* consumer_routine;
    co_create(&consumer_routine, NULL, Consumer, env);
    co_resume(consumer_routine);

    stCoRoutine_t* producer_routine;
```

2.2 对称协程与非对称协程

对称协程指调用者与被调用者是对等关系，子协程之间来回切换；
非对称协程指 被调协程让出 cpu 以后，必须回到调用协程；在实际应用中，非对称协程更好用；
Libco 属于非对称协程；

2.3 独占栈与共享栈

stackful coroutine：
libco 的协程是 stackful coroutine: 每个协程都拥有一个独立的栈帧, 协程切换时会保存当前协程栈中的所有数据, 并加载新的栈帧对象. 这样做的优点是: 协程调度可以在内存中的任意位置、任意时刻进行; 但是缺点也很明显: 随着并发量的增加, 协程的数目越来越多, 当前内存中的协程栈(无论是 occupy 还是 suspend)越来越多, 内存瓶颈开始显现, 且内存切换本身也是不小的开销(寄存器恢复、数据拷贝). 所以, stackful coroutine 一般有栈大小的限制(libco 是 128K).

stackful coroutine：

那么能不能所有正在执行的协程都共享一个栈呢?这就是共享栈的思路. 共享栈将协程划分为协程组, 同一个协程组中的协程共享同一块内存, 在协程切换的时候将当前内存中的数据保存到运行协程的 buffer 中, 并将新调度协程 buffer 中的数据拷贝到共享栈中. 如此既可以减少内存开销, 同时运行协程又没有了栈大小的限制. 但是"鱼和熊掌不可兼得"(我居然会用谚语 orz), 共享栈的缺点是: 协程调度产生的局部变量都在共享栈上, 一旦新的协程运行后共享栈中的数据就会被覆盖, 先前协程的局部变量也就不再有效, 进而无法实现参数传递、嵌套调用等高级协程交互. 不过 libco 作为一个生产库, 不是研究协程语法的, 每个协程作为一个"原子"的调用例程就够用了.
此外, libco 的协程在共享栈上的切换还实现了 copy-on-write, 只有共享栈内存改变时才进行数据拷贝, 这是传统的 stackful coroutine 所无法实现的.

3 协程的原理

协程是通过汇编语言来保存和恢复函数执行上下文、使用 IO 事件或者定时器事件来控制 CPU 的执行策略来实现的；
下图分别表示协程的内存分布及基本调度原理；

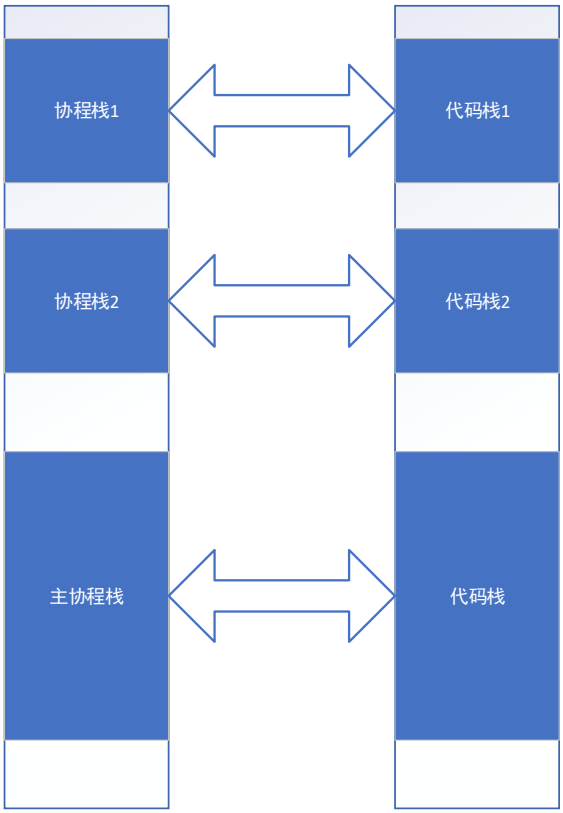

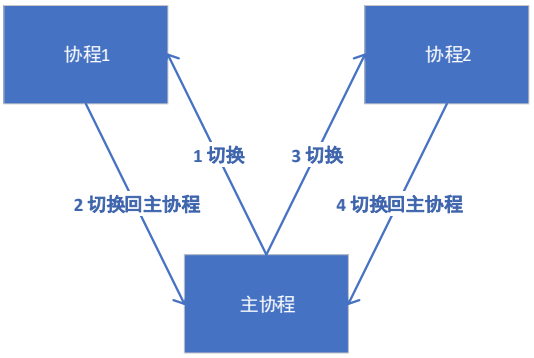

3.1 函数调用栈

其基本知道，可以先阅读此文 https://nifengz.com/introduction_x64_assembly/；

恢复函数调用的上下文，主要由以下内容决定：

1） 通用寄存器

X86-64 有 16 个通用(几乎都是通用的)64 位整数寄存器：

%rax	%rbx	%rcx	%rdx	%rsi	%rdi	%rbp	%rsp	%r8	%r9	%r10	%r11	%r12	%r13	%r14	%r15

2） RIP 寄存器

3） 栈空间

其中主要的寄存器说明：

1）RIP 指向汇编代码栈的指令地址，表示即将要执行的指令；

2）RSP 表示栈顶寄存器；

3）RBP 表示栈底寄存器；

4）RAX 为函数返回值的存储寄存器；

5）RDI 通常存储函数的第 1 个参数地址，RSI 通常存储函数的第 2 个参数地址；

示例：

```c
#include <stdio.h>

int sum(int a, int b)
{
    int c = a + b;
    return c;
}
int main()
{
    int x = sum(1, 2);
    printf("result is:%d\n", x);
    return 0;
}
```

对应的堆栈变化如下：

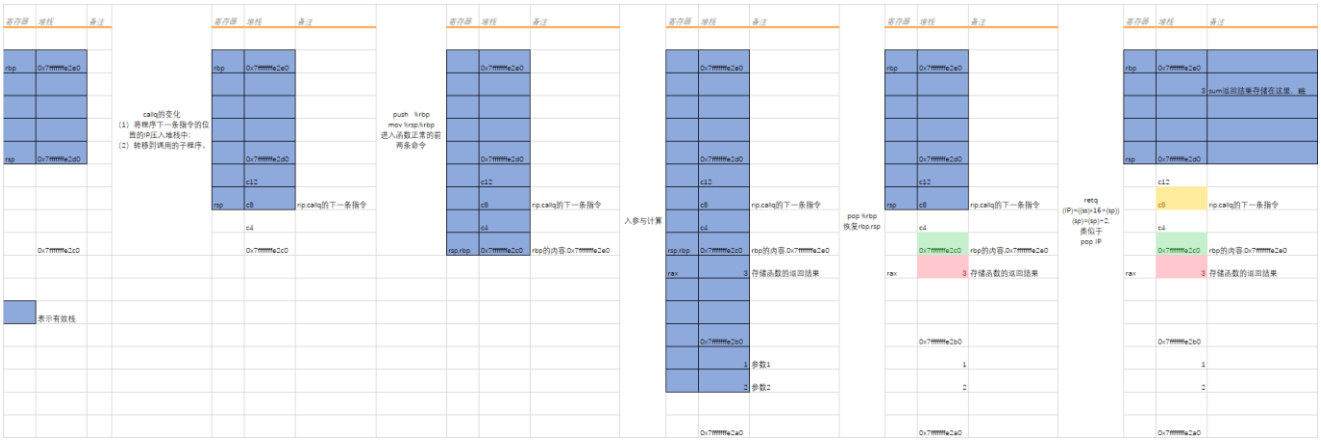

3.2 保存&恢复上下文

用户可以在 IO 阻塞的地方让出 CPU，等待 IO 处理完成以后，再恢复执行；在 libco 中通过 coctx_make、co_swap 来实现；

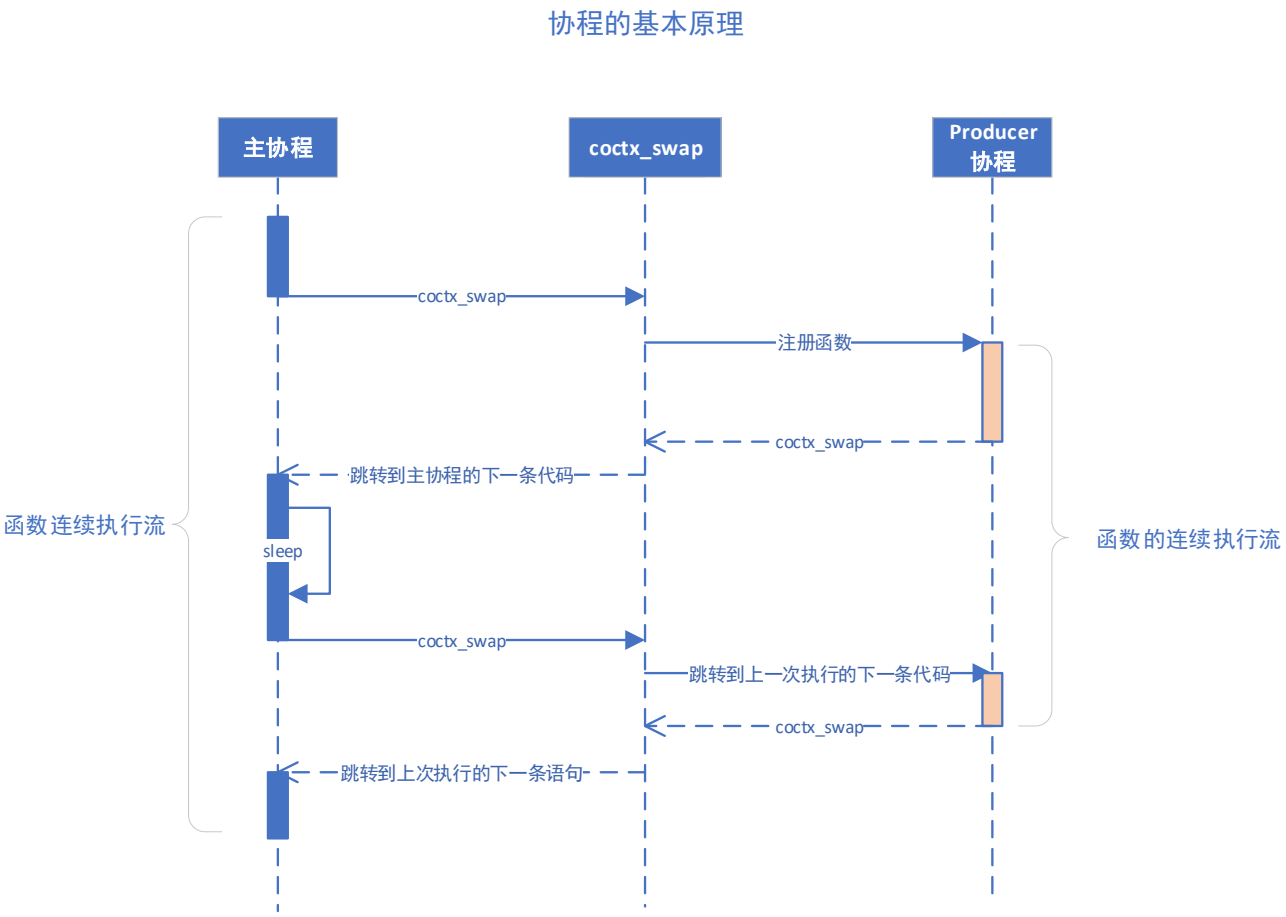

其中，协中 CPU 的保存与恢复，是通过 coctx_swap.S 文件实现，以下为 64 位的 CPU 的汇编代码：

coctx_swap.S (D:\code\libco) × co_hook_sys_c

```
#elif defined(__x86_64__)
    leaq 8(%rsp),%rax
    leaq 112(%rdi),%rsp
    pushq %rax
    pushq %rbx
    pushq %rcx
    pushq %rdx

    pushq -8(%rax) //ret func addr

    pushq %rsi
    pushq %rdi
    pushq %rbp
    pushq %r8
    pushq %r9
    pushq %r12
    pushq %r13
    pushq %r14
    pushq %r15

    movq %rsi, %rsp
    popq %r15
    popq %r14
    popq %r13
    popq %r12
    popq %r9
    popq %r8
    popq %rbp
    popq %rdi
    popq %rsi
    popq %rax //ret func addr
    popq %rdx
    popq %rcx
    popq %rbx
    popq %rsp

    pushq %rax

    xorl %eax, %eax
    ret

#endif
```

8（%rsp）保存的是call coctx_swap 的下一条指令地址；

保存当前的运行环境到第一个入参中；
push -8(%rax) 即保存coctx_swap的下一条指令到数组中

将第二个入参的参数恢复运行环境，这一步已经完成了寄存器的恢复

恢复rip,先将入代码栈的地址入栈，再利用ret 的运行原理出栈（类似于pop rip），恢复rip

以上汇编的主要逻辑可以用下图表示；

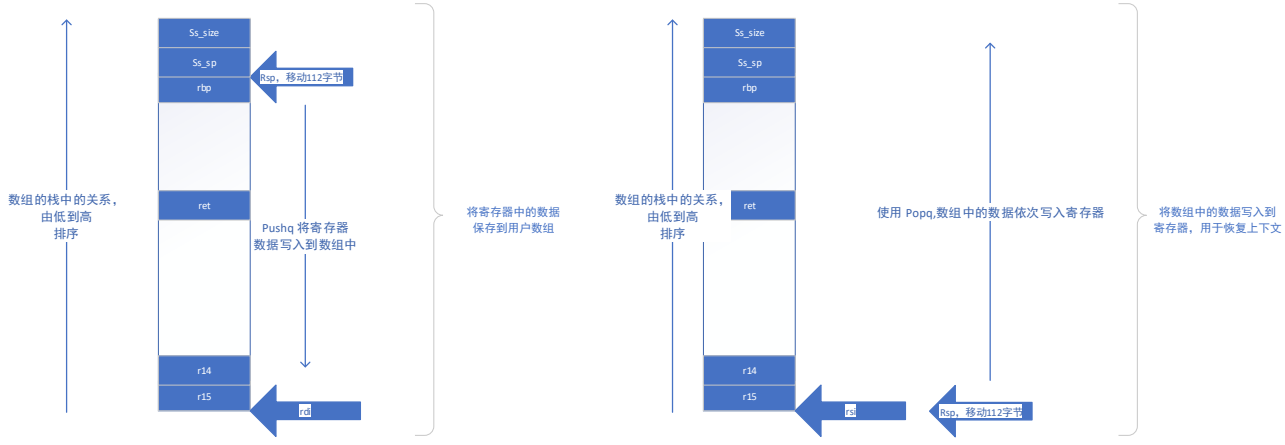

3.3 任务调度

拿生产者与消息者的示例来描述任务调度的原理：

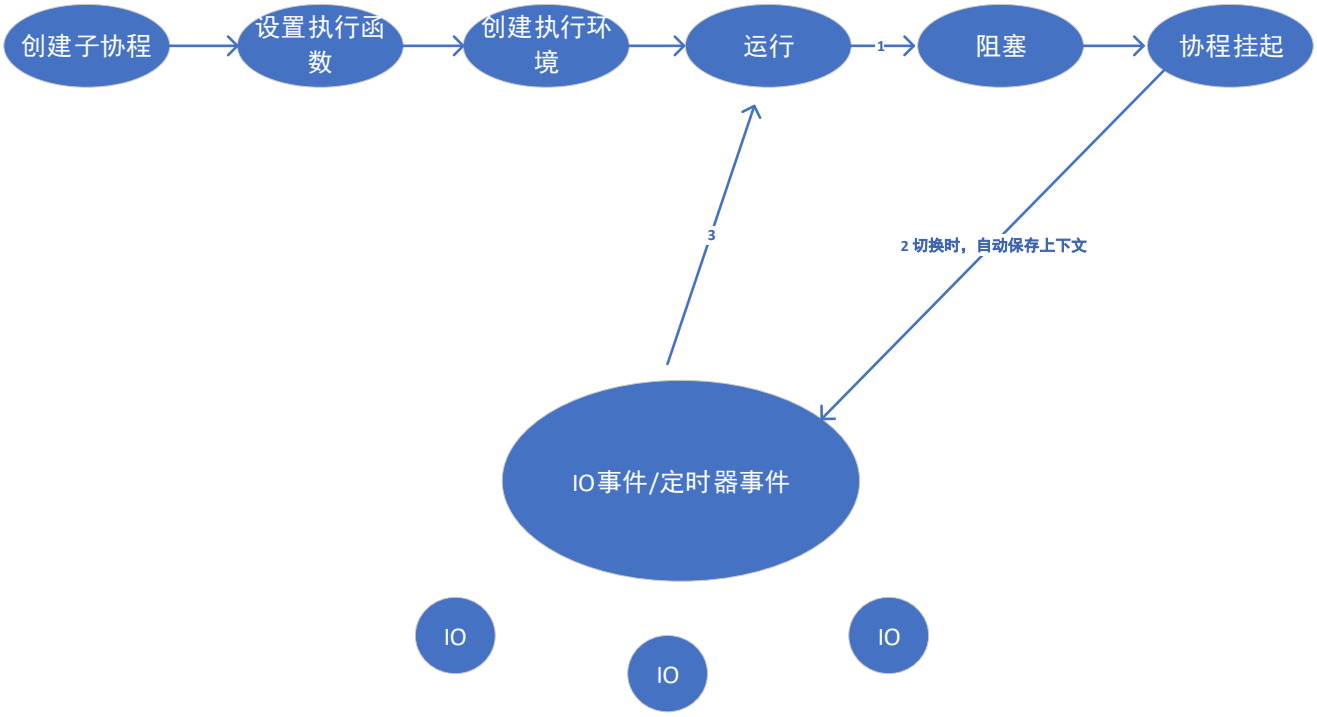

3.3.1 co_resume

切入协程，获取 CPU；

3.3.2 co_yield_ct

切出当前协程，让出 CPU

3.3.3 co_swap

协程切换的核心函数，通过汇编实现；

3.4 协程同步

3.4.1 co_cond_timedwait

将当前协程数据添加到同步事件单向链接中；

3.4.2 co_cond_signal

从同步事件单向链接中取出协程数据，放入活跃的待处理单向链接中；

3.4.3 co_cond_broadcast

从同步事件的单向链接中取出所有的协程数据，全部放入活跃的待处单向链接中；

3.4.4 co_eventloop

从活跃链表中依次取出协程数据处理；

简单理解为如下图：

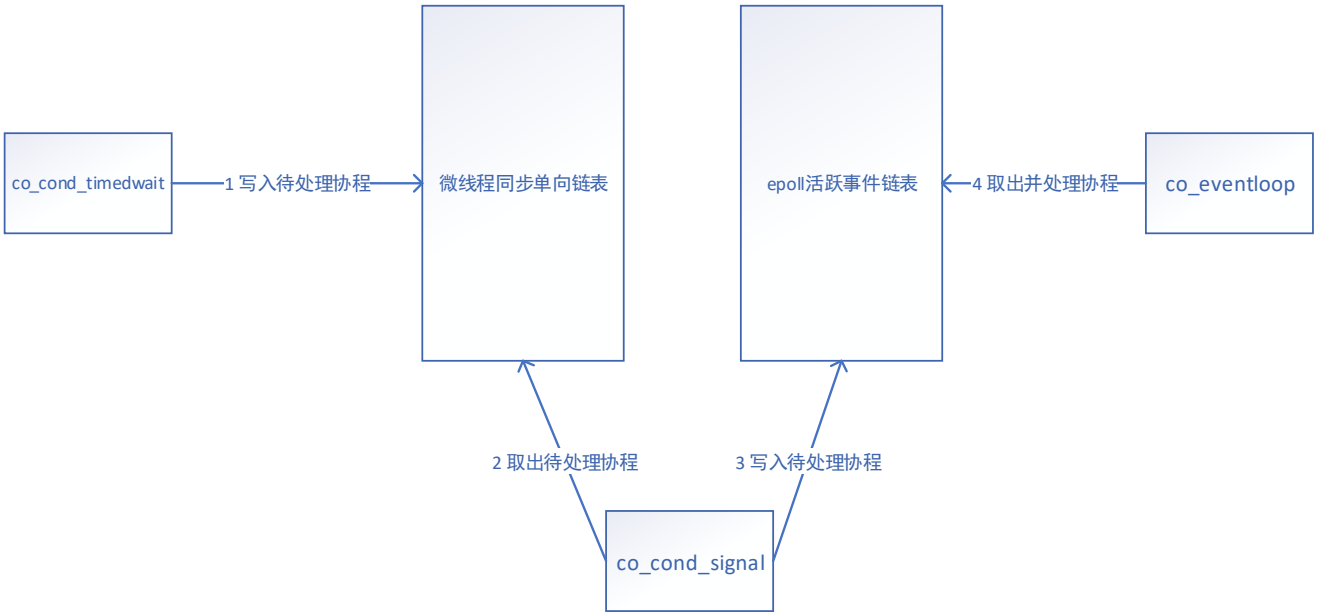

详细计录：

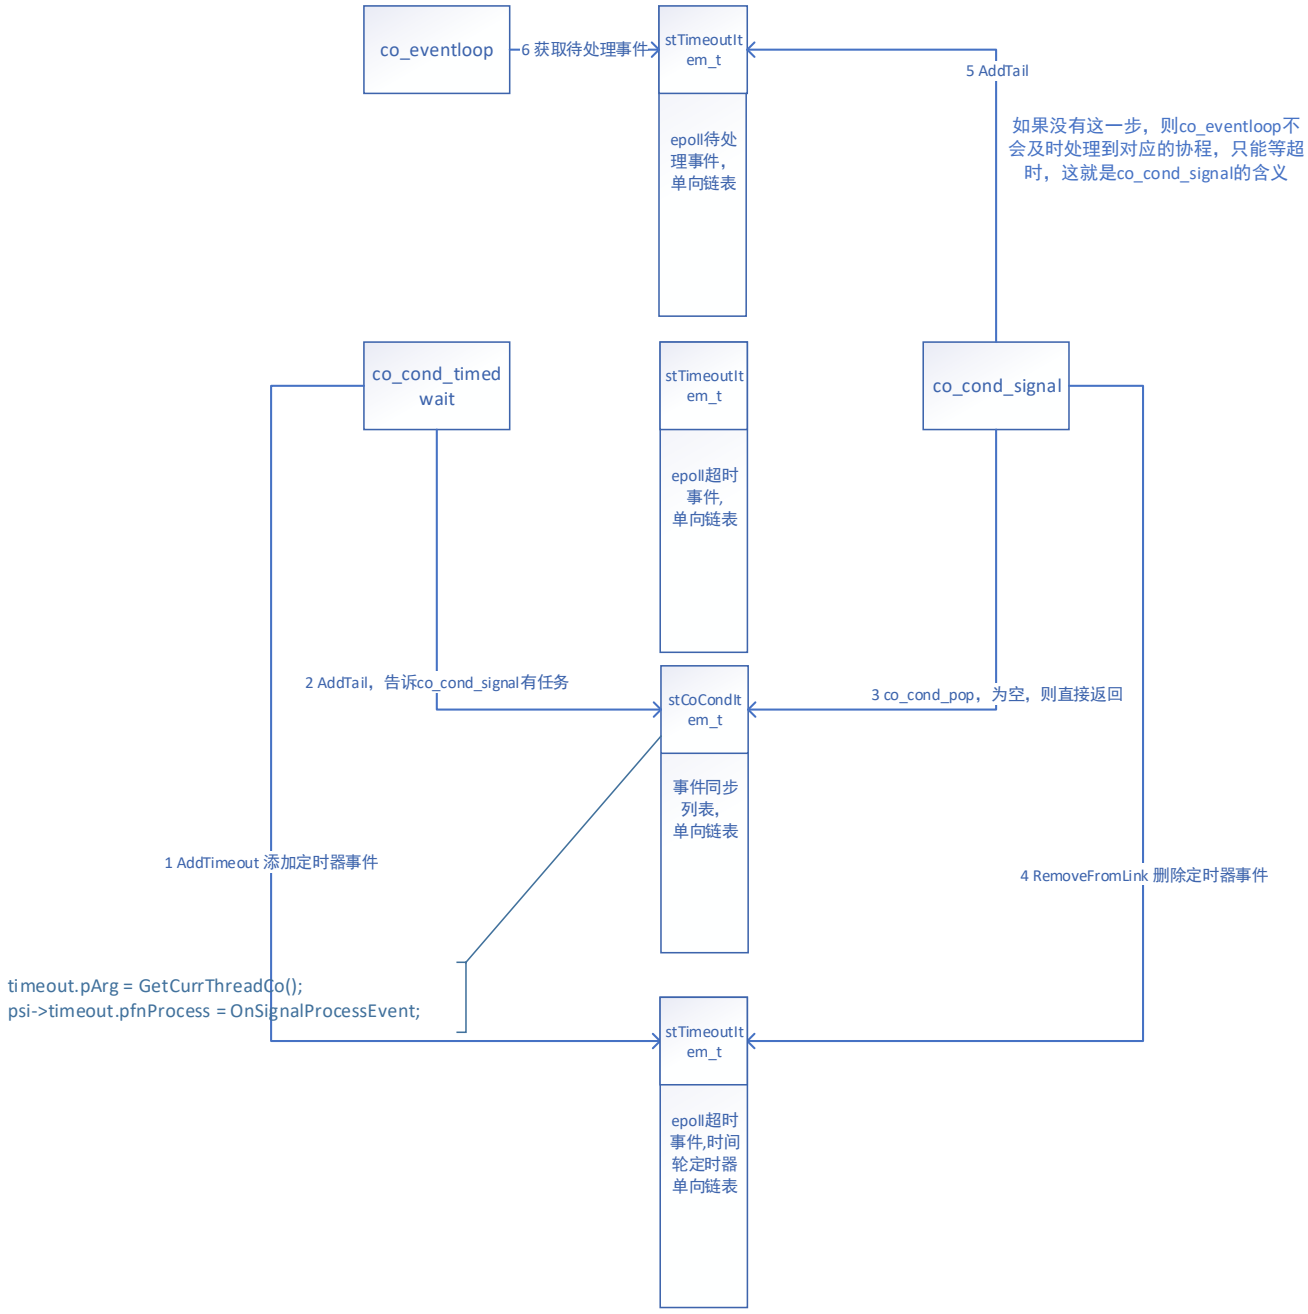

3.5 其它函数

3.5.1 Poll

调用 co_poll_inner 函数，插入一条超时任务：

arg.pfnProcess = OnPollProcessEvent;

arg.pArg = GetCurrCo(co_get_curr_thread_env());

unsigned long long now = GetTickMS();

arg.ullExpireTime = now + timeout;

int ret = AddTimeout(ctx->pTimeout,&arg,now);//注册定时器

待定时任务回来时，执行该协程时，删除这条定时任务；

RemoveFromLink<stTimeoutItem_t,stTimeoutItemLink_t>(&arg);//删除定时器

4 数据结构

4.1 协程环境

```
struct stCoRoutineEnv_t
{
    stCoRoutine_t *pCallStack[ 128 ];
    int iCallStackSize;
    stCoEpoll_t *pEpoll;

    //for copy stack log lastco and nextco
    stCoRoutine_t* pending_co;
    stCoRoutine_t* ocupy_co;
};
```

其中 pCallStack[0]存储的是主协程，pCallStack[1]存储的是当前正在运行的协程，在生产者与消息费者的示例中，pCallStack 只会使用到前两个数组，对于挂起的协程环境是存储在事件的双向链表中，都过事件触发机制来控制；

pEpoll 表示 EPOLL IO 管理器，是结合定时器或者 IO 事件来管理协程的调度的；

```
struct stCoRoutine_t
{
    stCoRoutineEnv_t *env;
    pfn_co_routine_t pfn;
    void *arg;
    coctx_t ctx;

    char cStart;
    char cEnd;
    char cIsMain;
    char cEnableSysHook;
    char cIsShareStack;

    void *pvEnv;

    //char sRunStack[ 1024 * 128 ];
    stStackMem_t* stack_mem;


    //save satck buffer while confilct on same stack_buffer;
    char* stack_sp;
    unsigned int save_size;
    char* save_buffer;

    stCoSpec_t aSpec[1024];

};
```

以上结构表示某个协程的具体内容，pfn 表示该协程对应的执行函数指针；

ctx 存储的是当前协程的上下文，在调用 co_swap 时使用；

cIsShareStack 是否使用协程的共享栈模式；

4.2 协程栈空间

```
struct coctx_t
{
#if defined(__i386__)
    void *regs[ 8 ];
#else
    void *regs[ 14 ];
#endif
    size_t ss_size;
    char *ss_sp;

};
```

上面为保存寄存器的数据结构，64 位 CPU 常用寄存器为 14 个；其中 ss_sp 表示创建协程环境时，为协程分配的栈空间的低地址，ss_size =128 * 1024;表示栈空间大小，运行栈函数时，rsp,rbp 都将指向这一段空间运行，也即协程执行函数的分配将会在这段空间，如果栈中的临时变量占用函数超过这块栈空间，则出错；每个协程都会默认创建一段大小为 ss_size 的栈空间；

4.3 EPOLL

```
struct stCoEpoll_t
{
    int iEpollFd;
    static const int _EPOLL_SIZE = 1024 * 10;

    struct stTimeout_t *pTimeout; // 时间轮定时器

    struct stTimeoutItemLink_t *pstTimeoutList; // 已经超时的时间

    struct stTimeoutItemLink_t *pstActiveList; // 活跃的事件

    co_epoll_res *result;

};
```

4.1 双向链表

Epoll 的数据结构中都有使用到；

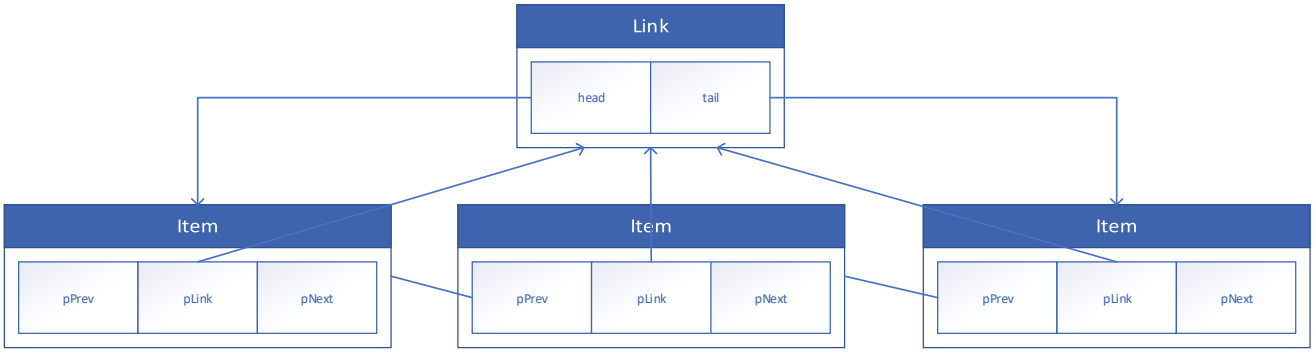

4.2 定时器

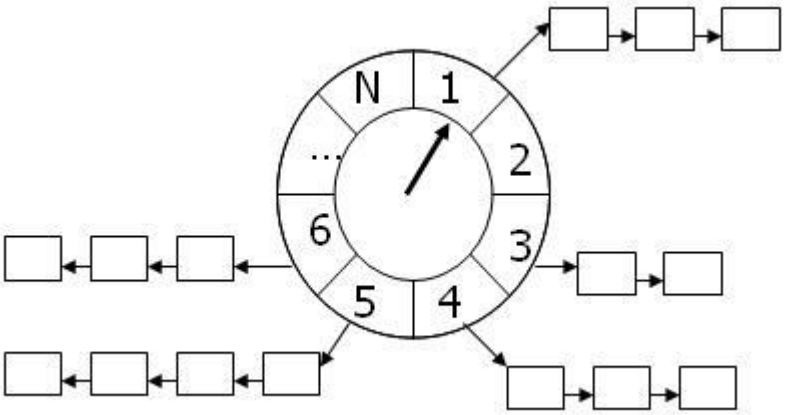

LIBCO 是采用时间轮的定时器，最小单位为 1ms，最大长度为 40s；

5 HOOK 机制

Libco 将 linux 的 IO 相关的函数阻塞函数重新实现了，将在其中注入 Epoll 或者定时器事件，有以下函数：

- Socket
- Co_accept
- Connect
- Close
- Read
- Write
- Sendto
- Recvfrom

- Send
- Recv

在调用前，可以通过调用 co_enable_hook_sys() 来决定 ，是否使用 Hook 机制，实现同步代码与异步代码的优雅切换；

示例：

```
ssize_t read( int fd, void *buf, size_t nbyte )
{
    HOOK_SYS_FUNC( read );

    if( !co_is_enable_sys_hook() )
    {
        return g_sys_read_func( fd,buf,nbyte );
    }
    rpchook_t *lp = get_by_fd( fd );

    if( !lp || ( O_NONBLOCK & lp->user_flag ) )
    {
        ssize_t ret = g_sys_read_func( fd,buf,nbyte );
        return ret;
    }
    int timeout = ( lp->read_timeout.tv_sec * 1000 )
                + ( lp->read_timeout.tv_usec / 1000 );

    struct pollfd pf = { 0 };
    pf.fd = fd;
    pf.events = ( POLLIN | POLLERR | POLLHUP );

    int pollret = poll( &pf,1,timeout );

    ssize_t readret = g_sys_read_func( fd,(char*)buf ,nbyte );

    if( readret < 0 )
    {
        co_log_err("CO_ERR: read fd %d ret %ld errno %d poll ret %d timeout %d",
                   fd,readret,errno,pollret,timeout);
    }

    return readret;

} « end read »
```

通过epoll来管理

6 源码分析

6.1 Example_cond 生产者与消息者示例

6.2 Example_echocli 异步客户端

6.3 Example_echosvr 搭建一个简单的服务

1) 可以启动多个进程，同时 accept，linux 2.6 版本以后，多进程同时 accept 只有一个生效；

2) 每个进程一个 accept 协程，循环处理；

3) 每个进程多个协程，每个协程对应一个长链接，对于多长链接请求，需要启动多个协程；

4) 进程 for 循环前，通过队列实现协程间的同步通知；

```
        for(;;)
        {
            struct pollfd pf = { 0 };
            pf.fd = fd;
            pf.events = (POLLIN|POLLERR|POLLHUP);
            co_poll( co_get_epoll_ct(),&pf,1,1000);

            int ret = read( fd,buf,sizeof(buf) );
            if( ret > 0 )
            {
                ret = write( fd,buf,ret );
            }
            if( ret <= 0 )
            {
                close( fd );
                break;
            }
        }

    } « end for ;; »
    return 0;
} « end readwrite_routine »
int co_accept(int fd, struct sockaddr *addr, socklen_t *len );
static void *accept_routine( void * )
{
    co_enable_hook_sys();
    printf("accept_routine\n");
    fflush(stdout);
    for(;;)
    {
        //printf("pid %ld g_readwrite.size %ld\n",getpid(),g_readwrite.size());
        if( g_readwrite.empty() )
        {
            printf("empty\n"); //sleep
            struct pollfd pf = { 0 };
            pf.fd = -1;
            poll( &pf,1,1000);

            continue;

        }
        struct sockaddr_in addr; //maybe sockaddr_un;
        memset( &addr,0,sizeof(addr) );
        socklen_t len = sizeof(addr);

        int fd = co_accept(g_listen_fd, (struct sockaddr *)&addr, &len);
        if( fd < 0 )
        {
            struct pollfd pf = { 0 };
            pf.fd = g_listen_fd;
            pf.events = (POLLIN|POLLERR|POLLHUP);
            co_poll( co_get_epoll_ct(),&pf,1,1000 );
            continue;
        }
        if( g_readwrite.empty() )
        {
            close( fd );
            continue;
        }
        SetNonBlock( fd );
        task_t *co = g_readwrite.top();
        co->fd = fd;
        g_readwrite.pop();
        co_resume( co->co );
    } « end for ;; »
```

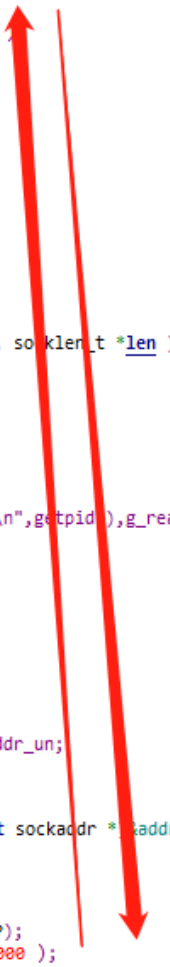

协程相互切换